HCI - Report: Anime

2025/2026 - Università degli studi di Torino - Dipartimento di Informatica

HCI - Report: Anime 0
1.Introduzione 1
2.Pulizia dei dati 1
3.Notebook di Storytelling - Analisi e Visualizzazione 2
4.Scelte Metodologiche e Trasparenza sui dati 3
5.Conclusioni 3
6.Divisione del lavoro 3
7.Informazioni aggiuntive 4
8.Bibliografia 4

1.Introduzione

Il progetto si è concentrato sull'analisi di una grande quantità di dati relativi al mondo degli anime.
L'obiettivo principale era **esplorare l'ecosistema degli anime attraverso i dati**, raccontando la loro evoluzione storica, la distribuzione dei generi, le fonti di ispirazione, la popolarità nel tempo e il ruolo dei doppiatori e dei fan.
Partendo dai file CSV forniti, abbiamo eseguito una pulizia accurata dei dati e sviluppato numerose visualizzazioni sia statiche che interattive all'interno di **Jupyter Notebook**. In questo modo il progetto descrive gli anime non solo come prodotti audiovisivi, ma come parte di un ecosistema culturale composto anche da chi li guarda, li valuta e contribuisce alla loro realizzazione.

2.Pulizia dei dati

Soluzione
La pulizia è organizzata in 13 notebooks dedicati (uno per file) nella cartella **solution/pulizia**. Ogni notebook applica una pipeline coerente: rimozione di righe nulle o duplicate, conversione dei tipi (date, numeri, booleani), standardizzazione dei campi categorici (nomi dei paesi, codici di stato) e scrittura dei file puliti in **dataset/cleaned.**
La scelta di un notebook per dataset, anziché uno script unico, ne facilita la documentazione e permette l'esecuzione indipendente delle singole pulizie.
Le funzionalità ricorrenti sono centralizzate nel modulo **solution/utils/utils.py.**
Problematiche
La principale difficoltà è stata la dimensione di alcuni file (in particolare ratings.csv).Alcuni punteggi storici pre-1960 risultano poco affidabili per via dell'esiguo numero di titoli e valutazioni disponibili. Questi interventi correttivi sono documentati nella sezione **Scelte Metodologiche.**
Requisiti
Il requisito di rendere i CSV grezzi, utilizzabili per analisi e visualizzazione è soddisfatto: i notebook di cleaning sono autosufficienti, riproducibili e producono dataset puliti riusati dal notebook di storytelling.
Limitazioni
Abbiamo fatto un ottimo lavoro di pulizia sui dati, ma vista la loro enorme quantità, è possibile che qualche elemento non sia stato filtrato alla perfezione.

3.Notebook di Storytelling - Analisi e Visualizzazione

Soluzione
Il notebook principale **solution/notebook/storytelling.ipynb** contiene 10 sezioni narrative che costruiscono un racconto progressivo sull'ecosistema anime. Per ciascuna sezione è stata identificata una domanda informativa, scelto il tipo di grafico più adatto (statico con matplotlib/seaborn, iterativo con plotly) e redatto un commento interpretativo.

Il lavoro è partito dall'evoluzione della produzione anime nel tempo, per poi approfondire generi, popolarità, valutazioni, personaggi, doppiatori e community. L'obiettivo non era

mostrare grafici separati, ma raccontare come il fenomeno anime si sia sviluppato negli anni e come coinvolga sia le opere prodotte sia le persone che le guardano e le valutano.

Problematiche
La sfida principale è stata trasformare un insieme di analisi indipendenti in un racconto unitario: i grafici sono stati riorganizzati per tema e i commenti raccordati per rendere fluido il passaggio tra sezioni. Diversi visualizzazioni iniziali sono state progettate per migliorare la leggibilità.

Alcuni grafici con i quali abbiamo riscontrato problematiche:

- **Distribuzione geografica della community:** Il campo location dei profili era testuale e non standardizzato, richiedendo normalizzazione manuale dei valori in codici ISO3 per garantire una copertura corretta di tutti i paesi nella mappa.

- **Distribuzione per genere:** Oltre il 50% degli utenti non ha compilato il campo genere, rendendo necessario raggruppare i valori mancanti in una categoria "Non dichiarato" per non alterare la rappresentatività del grafico.

- **Evoluzione dei generi nel tempo:** Durante il preprocessing del dataset è emersa una problematica nella gestione della colonna genres. I dati non erano salvati in un formato uniforme: alcune righe contenevano liste, altre stringhe separate da virgole o valori nulli.L'utilizzo diretto della funzione explode() di Pandas produceva quindi duplicazioni anomale delle righe e risultati incoerenti nelle statistiche aggregate. Questo problema influenzava in particolare:
  - il conteggio degli anime per genere;
  - il calcolo della media degli score;
  - le visualizzazioni comparative tra anni.

  Per risolvere il problema è stata effettuata una fase di normalizzazione della colonna genres, convertendo tutti i valori in liste omogenee prima di applicare explode()

Requisiti
Il notebook soddisfa il requisito di supportare analisi e visualizzazione per fan e giornalisti, fornendo un percorso guidato che non richiede competenze tecniche per essere letto e al contempo offre approfondimenti utili al pubblico esperto (medie ponderate, soglie minime di voti, viste corporate).

Limitazioni
Alcune visualizzazioni sono limitate dalla disponibilità e completezza dei dati nel dataset fornito, in particolare per i periodi storici più lontani.

4.Scelte Metodologiche e Trasparenza sui dati

Ogni grafico che esclude dati è accompagnato da una nota esplicita ("Nota sui dati") che quantifica l'esclusione. In particolare

- il 2,9% degli anime non ha data inizio (escluso dal grafico storico)
- il 20,7 % degli anime non ha tag di genere(escluso dai grafici sui generi)
- il 62,6 % degli anime non ha tag demografico

- il 75,6 % dello staff non ha data di nascita (il grafico generazionale copre solo il 24,4% restante)
- i punteggi medi pre-1960 sono poco affidabili per il numero ridotto di titoli e voti.
- la crescita della comunity esclude utenti con anno di iscrizione fuori dal range 2005-2024.

5.Conclusioni

Il progetto copre l'intero pipeline dal dato grezzo alla narrativa visualizzata: la fase di pulizia è modulare, mentre il notebook di storytelling segue una struttura narrativa coerente che porta il lettore dalla storia della produzione fino al comportamento della community, con attenzione costante alla correttezza dei dati e alla chiarezza comunicativa in linea con i principi di HCI di progettazione centrata sull'utente.

6.Divisione del lavoro

Il gruppo è composto da due persone, Giulia Zenoni e Kledisa Teqja. Il lavoro è stato condiviso in modo bilanciato: entrambe abbiamo partecipato a tutte le fasi (pulizia dei dati, analisi di dati, visualizzazione dei dati e storytelling). I 13 file CSV sono stati suddivisi in base alla coerenza tematica con le rispettive sezioni narrative: una componente si è occupata di 6 file e l'altra dei restanti 7, eseguendo per ciascuno l'intero ciclo pulizia-analisi-visualizzazione. Le funzioni comuni sono confluite nel modulo utils.py.

Il notebook di storytelling è stato costruito congiuntamente: definizione della linea narrativa, integrazione dei grafici nelle 10 sezioni, revisione dei commenti e correzione di problemi trasversali. Riunioni periodiche hanno permesso di allineare scelte progettuali, condividere codice e fornire assistenza reciproca.

7.Informazioni aggiuntive

Per eseguire la soluzione è sufficiente installare le dipendenze (pandas, numpy, matplotlib, seaborn, plotly) tramite

```Shell
pip install -r requirements.txt
```

I file CSV originali vanno collocati in **dataset/raw/**; i notebook di pulizia **solution/pulizia/** producono i file in **dataset/cleaned**, che vengono poi utilizzati dal notebook **solution/notebook/storytelling.ipynb.**

- **Tecnologie**: Python 3, Pandas, NumPy, Matplotlib, Seaborn e Plotly;
- **File di supporto**: utils.py (che si trova nella cartella dei notebook);
- **Esecuzione**: il file **README.md** fornisce istruzioni dettagliate.

Durante lo sviluppo del progetto abbiamo utilizzato strumenti di intelligenza artificiale come supporto per discutere idee di storytelling, migliorare la chiarezza dei titoli e dei commenti, rivedere alcune parti del codice e supportare la stesura del report. Le soluzioni proposte non sono state usate automaticamente, ma sono state controllate, comprese, adattate e testate all'interno del notebook.

8.Bibliografia

1. Dataset fornito per l'assignment HCI 2025/2026.
2. Materiale didattico del corso HCI 2025/2026.
3. Documentazione ufficiale Pandas, https://pandas.pydata.org/docs/
4. Documentazione ufficiale Matplotlib, https://matplotlib.org/stable/
5. Documentazione ufficiale Seaborn, https://seaborn.pydata.org/
6. Documentazione ufficiale Plotly, https://plotly.com/python/
7. OpenAI, ChatGPT, utilizzato come supporto per revisione del codice, organizzazione dello storytelling e stesura del report.